

Análise de Risco de Crédito: Previsão de Inadimplência

Disciplina: Data Science

Autores:

- Igor Zanette — Matrícula 198862
- Marco Antônio Santolin — Matrícula 198769
- Marcos Paulo de Medeiros — Matrícula 151994

Data: Junho de 2026

Repositório GitHub: <https://github.com/MrcSanto/credit-risk-analysis-ds>

Dataset: Credit Risk Dataset — Kaggle (<https://www.kaggle.com/datasets/laotse/credit-risk-dataset>)

1. Introdução

A inadimplência em operações de crédito representa um dos principais riscos para instituições financeiras. Identificar, antes da concessão, quais clientes têm maior probabilidade de não honrar um empréstimo permite tomar decisões mais embasadas, reduzir prejuízos e manter a saúde da carteira de crédito.

Este projeto desenvolve um **modelo de classificação binária** capaz de prever se um cliente será inadimplente (`loan_status = 1`) ou adimplente (`loan_status = 0`), a partir de características pessoais e do próprio empréstimo.

Questões e hipóteses iniciais

1. **Hipótese 1:** Quanto pior a nota de risco (`loan_grade`) e maior a taxa de juros (`loan_int_rate`), maior a probabilidade de inadimplência.
2. **Hipótese 2:** O comprometimento de renda (`loan_percent_income`) é um forte preditor — clientes que comprometem grande parte da renda têm dificuldade de pagar.
3. **Hipótese 3:** O histórico de calote (`cb_person_default_on_file`) aumenta significativamente o risco.

O fluxo de trabalho seguiu as etapas clássicas de Data Science: coleta e exploração dos dados, limpeza e engenharia de features, modelagem com múltiplos algoritmos, avaliação com métricas adequadas ao desbalanceamento da base e comunicação dos resultados via relatório e dashboard interativo.

2. Dataset

2.1 Origem e características gerais

Item	Detalhe
Fonte	Kaggle — Credit Risk Dataset
URL	https://www.kaggle.com/datasets/laotse/credit-risk-dataset
Registros (bruto)	32.581 linhas × 12 colunas
Variável-alvo	loan_status (1 = inadimplente, 0 = adimplente)
Desbalanceamento	~21,8% de inadimplentes

2.2 Dicionário de variáveis

Coluna	Tipo	Descrição
person_age	Numérica	Idade do cliente (anos)
person_income	Numérica	Renda anual (US\$)
person_home_ownership	Categórica	Tipo de moradia (RENT, OWN, MORTGAGE, OTHER)
person_emp_length	Numérica	Tempo de emprego (anos)
loan_intent	Categórica	Finalidade do empréstimo (PERSONAL, EDUCATION, MEDICAL, VENTURE, HOMEIMPROVEMENT, DEBTCONSOLIDATION)
loan_grade	Categórica ordinal	Nota de risco do empréstimo (A a G, onde G = maior risco)
loan_amnt	Numérica	Valor do empréstimo (US\$)
loan_int_rate	Numérica	Taxa de juros anual (%)
loan_status	Binária	Alvo — 1 = inadimplente, 0 = adimplente
loan_percent_income	Numérica	Razão empréstimo / renda anual
cb_person_default_on_file	Binária	Histórico de calote (Y = sim, N = não)
cb_person_cred_hist_length	Numérica	Tempo de histórico de crédito (anos)

Dataset bruto: 32,581 linhas × 12 colunas

Dataset limpo: 32,409 linhas × 12 colunas

Removidas: 172 linhas (0.53%)

2.3 Qualidade dos dados e limpeza

A análise exploratória inicial revelou três problemas de qualidade:

=== PROBLEMAS ENCONTRADOS NO DATASET BRUTO ===

1. Duplicatas: 165 linhas
2. Valores ausentes:
person_emp_length: 895 (2.75%)
loan_int_rate: 3116 (9.56%)
3. Outliers impossíveis:
person_age > 100: 5 registros (ex.: idade 144)
person_emp_length > 60: 2 registros (ex.: 123 anos de emprego)

=== ETAPAS DE LIMPEZA APLICADAS ===

1. Remoção de linhas duplicadas
2. Remoção de outliers impossíveis (person_age > 100, person_emp_length > 60)
3. Imputação de ausentes pela mediana (loan_int_rate, person_emp_length)

Dataset final: 32,409 linhas (manteve 99.5% dos dados)

2.4 Engenharia de features

Três novas variáveis foram criadas dentro do pipeline de modelagem (sem risco de data leakage, pois são calculadas linha a linha):


Feature criada	Fórmula	Interpretação
loan_to_income_ratio	$\frac{\text{loan_amnt}}{\text{person_income}}$	Proporção do empréstimo sobre a renda
loan_to_emp_length_ratio	$\frac{\text{person_emp_length}}{\text{loan_amnt}}$	Estabilidade do emprego relativa ao valor
int_rate_to_loan_amt_ratio	$\frac{\text{loan_int_rate}}{\text{loan_amnt}}$	Custo relativo dos juros

As variáveis categóricas receberam **One-Hot Encoding** e as numéricas foram **padronizadas** (StandardScaler), ambas dentro do pipeline para evitar vazamento de dados.

3. Análise Exploratória de Dados

3.1 Variável-alvo — balanceamento


Distribuição da variável-alvo (loan_status)



A base é **desbalanceada**: apenas 21,9% dos registros são inadimplentes. Por isso, a acurácia isolada é uma métrica enganosa — um modelo que classifique todos como adimplentes teria 78% de acurácia sem ser útil. Optamos por avaliar com **ROC-AUC, Recall e F1**, e treinamos todos os modelos com `class_weight='balanced'`.

3.2 Inadimplência por variáveis categóricas

Hipótese 1: Quanto pior a nota de risco, maior a inadimplência.




Confirmação hipótese 1: a taxa de inadimplência cresce monotonicamente de A → G.
Nota A: 10.0% | Nota G: 98.4%

A hipótese 1 é confirmada: a inadimplência cresce monotonicamente de A para G, com a nota G apresentando taxa ~8× maior que a nota A. Em relação à finalidade, empréstimos para **Venture** e **Education** apresentam as maiores taxas de inadimplência.

3.3 Variáveis numéricas vs. inadimplência

Hipótese 2: Maior comprometimento de renda → maior risco.

Variáveis numéricas vs. inadimplência



Os boxplots confirmam a **Hipótese 2**: inadimplentes apresentam taxa de juros mediana e comprometimento de renda claramente superiores. Inadimplentes também tendem a ter renda mais baixa, o que agrava a dificuldade de pagamento.

Taxa de inadimplência por histórico de calote:


Sem histórico de calote (N): 18.4%

Com histórico de calote (Y): 37.9%

Diferença: +19.4 p.p.

A **Hipótese 3** também é confirmada: clientes com histórico de calote têm taxa de inadimplência significativamente maior.

3.4 Correlações entre variáveis numéricas



Correlação com `loan_status` ($|r|$):

- `loan_percent_income`: 0.380
- `loan_int_rate`: 0.320
- `person_income`: 0.169
- `loan_amnt`: 0.106
- `person_emp_length`: 0.086
- `person_age`: 0.022
- `cb_person_cred_hist_length`: 0.016

As maiores correlações com a variável-alvo são `loan_int_rate` e `loan_percent_income`, reforçando as hipóteses levantadas. As correlações são moderadas, indicando relações não-lineares que justificam o uso de modelos baseados em árvore.

4. Modelagem

4.1 Estratégia e pipeline

O dataset limpo foi dividido em **80% treino / 20% teste** de forma estratificada (mantém a proporção de inadimplentes em ambos os conjuntos). Todo o pré-processamento foi encapsulado em um `Pipeline` do scikit-learn ajustado apenas no conjunto de treino, evitando data leakage.

O pipeline completo para cada modelo:

dados brutos → FunctionTransformer (build_features) →
ColumnTransformer (encoding + scaling) → Classificador

4.2 Modelos treinados e justificativa

Modelo	Justificativa
Regressão Logística	Baseline linear; interpretável e rápido de treinar
Random Forest	Ensemble de árvores; captura não-linearidades; robusto a outliers
HistGradientBoosting	Boosting moderno; melhor performance em dados tabulares desbalanceados


Todos usaram `class_weight='balanced'`, que pondera mais os erros na classe minoritária (inadimplentes), melhorando o **recall** — métrica mais crítica no contexto de crédito, onde um falso negativo (deixar passar um mau pagador) costuma custar mais que um falso positivo (recusar um bom pagador).

5. Resultados e Discussão

5.1 Comparação de desempenho


=== MÉTRICAS NO CONJUNTO DE TESTE ===

	ROC-AUC	Recall	F1	Acurácia
Modelo				
HistGradientBoosting	0.95	0.81	0.81	0.92
Random Forest	0.94	0.72	0.83	0.92
Regressão Logística	0.88	0.80	0.66	0.84



O **HistGradientBoosting** foi o modelo escolhido por apresentar o melhor **ROC-AUC (0,95)** e o melhor **Recall (0,81)** — o que significa que identifica corretamente 81% dos clientes inadimplentes no conjunto de teste.

5.2 Análise detalhada do modelo escolhido



Verdadeiros negativos (adimplentes corretamente identificados): 4,811
 Falsos positivos (bons pagadores recusados): 253
 Falsos negativos (maus pagadores aprovados – risco maior): 269
 Verdadeiros positivos (inadimplentes corretamente barrados): 1,149

5.3 Métricas clássicas de risco de crédito: KS e Gini

Em *credit scoring*, além da ROC-AUC são padrão de mercado a estatística **KS** (Kolmogorov–Smirnov) — máxima separação entre as distribuições acumuladas de bons e maus pagadores ao longo do score — e o **Gini** ($= 2 \cdot \text{ROC-AUC} - 1$). Quanto maiores, maior o poder de discriminação do modelo.

=== MÉTRICAS DE RISCO DE CRÉDITO (conjunto de teste) ===
 KS : 0.756
 Gini : 0.897 (= 2 x ROC-AUC - 1)
 AUC : 0.949

5.4 Validação cruzada estratificada

O desempenho acima provém de uma única partição treino/teste. Para avaliar a **estabilidade** do modelo, aplicamos validação cruzada estratificada (`StratifiedKFold`, 5 folds) sobre todo o conjunto, medindo a ROC-AUC em cada partição.

=== VALIDAÇÃO CRUZADA (ROC-AUC, 5 folds) ===
 Folds : [0.942 0.95 0.944 0.944 0.948]
 Média : 0.946 +/- 0.003

5.5 Inferência estatística com `statsmodels`: odds ratios

O pipeline `scikit-learn` é voltado à **predição** (fit/predict, validação cruzada, métricas). Para **inferência** — entender *quanto e com que significância* cada variável afeta o risco — ajustamos em paralelo uma regressão logística com `statsmodels`, que fornece coeficientes, p-valores e intervalos de confiança. Reportamos os **odds ratios** ($\text{OR} = \exp(\text{coef})$): $\text{OR} > 1$ aumenta as chances de inadimplência. As variáveis numéricas foram padronizadas (OR por 1 desvio-padrão) e as categóricas usam a primeira categoria como referência (`loan_grade` = A; histórico de calote = N).

Convergiu: True | pseudo R2 = 0.355

```
=== ODDS RATIOS – variáveis-chave (numéricos por 1 desvio-padrão) ===
                                odds_ratio  p_valor  IC95_inf  IC95_sup
C(loan_grade)[T.B]              1.250    0.002    1.087    1.437
C(loan_grade)[T.C]              1.558    0.000    1.276    1.901
C(loan_grade)[T.D]             12.630    0.000    9.894   16.122
C(loan_grade)[T.E]             16.726    0.000   12.148   23.028
C(loan_grade)[T.F]             24.291    0.000   15.198   38.826
C(loan_grade)[T.G]            744.576    0.000  95.907 5780.512
C(cb_person_default_on_file)[T.Y]  0.984    0.780    0.882    1.099
loan_int_rate                   1.205    0.000    1.104    1.315
loan_percent_income             4.248    0.000    3.995    4.517
```

5.6 Interpretação dos resultados

Matriz de confusão: no conjunto de teste com 6.482 amostras, o modelo:

- Identificou corretamente **1.149 dos 1.418 inadimplentes** (recall 81%)
- Cometeu apenas **269 falsos negativos** (maus pagadores aprovados indevidamente)
- Recusou erroneamente **253 bons pagadores** (falsos positivos)

Importância das features: as três variáveis com maior impacto no ROC-AUC quando embaralhadas são `loan_grade`, `loan_int_rate` e `loan_percent_income` — exatamente as que as hipóteses iniciais apontavam como mais relevantes. Isso valida tanto o modelo quanto a análise exploratória.

Comparação entre modelos: o Random Forest apresentou F1 ligeiramente superior (0,83 vs 0,81), mas com recall inferior (0,72 vs 0,81). No contexto de crédito, perder inadimplentes é mais custoso do que recusar bons pagadores, o que justifica priorizar o **recall** e escolher o HistGradientBoosting.

6. Conclusão

Este projeto desenvolveu um sistema completo de análise de risco de crédito, desde a exploração dos dados até um dashboard interativo para apoio à decisão.

Principais resultados

- O **HistGradientBoosting** atingiu **ROC-AUC de 0,95** e **Recall de 0,81** na classe de inadimplentes
- As três hipóteses iniciais foram confirmadas: `loan_grade`, `loan_int_rate` e `loan_percent_income` são os principais preditores de inadimplência
- O desbalanceamento (22% de inadimplentes) foi tratado com `class_weight='balanced'`, garantindo que o modelo identifique adequadamente a classe minoritária

Limitações

1. **Viés do `loan_grade`** : esta variável já é uma avaliação de risco feita pelo credor, o que pode superestimar a performance do modelo em cenários onde essa informação não estaria disponível no momento da decisão

2. **Dataset estático:** o modelo foi treinado em dados históricos; padrões de inadimplência podem mudar ao longo do tempo (concept drift)
3. **Ausência de variáveis externas:** dados macroeconômicos (taxa de desemprego, inflação) não foram incluídos e poderiam enriquecer o modelo

Trabalhos futuros

- Incorporar dados macroeconômicos como features externas
- Avaliar o modelo sem `loan_grade` para simular cenários onde a nota não está disponível previamente
- Implementar monitoramento de drift para atualização periódica do modelo
- Explorar técnicas de explicabilidade como SHAP para interpretar previsões individuais

Repositório: <https://github.com/MrcSanto/credit-risk-analysis-ds>

Dashboard: executar `python -m streamlit run dashboard/app.py` (ou `make dashboard`)